


Análisis de intervención



Preámbulo

- Los análisis descriptivos y técnicas vistas hasta ahora son aproximaciones a las observaciones mediante métodos que tratan de explicar o aproximar una tendencia. Antes se decía que los 4 roles fundamentales de un Estadístico eran: describir, inferir, asignar y por último suavizar cierto acontecimiento...
- El proceso de suavizar o aproximar cierto evento se complica cuando se posee un cambio estructural (coyuntura) o valores extremos que dificulta, o también no realiza una apropiada aproximación de cierta parte de la serie dado estos cambios.
- ¿Qué conocemos o que solemos hacer cuando algo así sucedía?
- En el presente curso aplicamos un tipo de intervención para los modelos de regresión no lineales... pero no se discutió ni se formuló de la mejor forma.



Preámbulo

- En dónde es que podríamos encontrarnos con un posible análisis de intervención:

1. Cambio de política económica.
2. Perdida repentina de la clientela.
3. Modificaciones estructurales de la empresa.
4. Desastre natural en perdidas de cultivos.
5. Reforma asignativa en los salarios.
6. Cambio de gobierno.
7. Ley de control del gasto, etc., etc., etc.,



- Cada uno de los ejemplos anteriores son casos donde el análisis de intervención se podría aplicar.

Preámbulo

¿Qué es lo que los ejemplos anteriores poseen en el análisis de las series para poder emprender una intervención?



Preámbulo

- Normalmente TODO análisis de intervención requiere de un conocimiento de la serie para saber exactamente qué acontecimiento sucedió y por lo tanto el querer ajustar una intervención en un período t , o diversos periodos t_i ...

ANSWER

Índice

1

Fundamentos

4

Efectos de calendario

2

¿Por qué debemos analizarlo
de forma diferente?

5

Valores faltantes y valores
extremos

3

Modelo ARIMA con
intervención

6

Consejos finales

Índice

1

Fundamentos

Fundamento

- Es frecuente que al construir modelos para series de tiempo, se observen residuos mayores a lo esperado para un determinado tiempo t , producto de una seguidilla de valores cambiantes o un único valor muy cambiante.
- Estos residuos anormales (o en inglés como *outliers*) pueden ser el resultado de la ocurrencia de fenómenos ajenos al comportamiento histórico de la serie (recordar que no todo es producto de la técnica de análisis como tal).
- Como consecuencia, en ocasiones impiden una buena identificación de un modelo de series de tiempo, para nuestros modelos de segunda generación, un ARIMA, ya que introducen correlaciones significativas en las FAC dadas estas ocurrencias inherentes al proceso que estamos analizando... y esto es algo bastante común y molesto...



Fundamento


- Por lo anterior, es importante llevar a cabo lo que se conoce como un *análisis de intervención*. Este tipo de análisis busca erradicar los altos residuos o outliers detectados en el análisis, productos de eventos intrínsecos a la serie que se está analizando.
- Es importante mencionar que se debe de evitar el uso del análisis de intervención para reducir arbitrariamente la magnitud de residuales con valores grandes; y debe aplicarse únicamente cuando exista el conocimiento de que un fenómeno exógeno tuvo lugar en un momento preciso del tiempo t_0 . De forma empírica se puede llevar a cabo, pero no es el objetivo como tal, dado que este puede ser explicado.
- En contra parte, recordemos que los eventos aleatorios pueden conducir a valores extremos, por lo que se recomienda la reflexión a la hora de aplicar la intervención.... (...¿entonces?...)



Fundamento


Una intervención puede ser interpretada como el efecto de la ocurrencia de un *evento exógeno* sobre el comportamiento histórico de una serie. Ejemplos, ya mencionados, de eventos exógenos:

- Cambio de política económica: el cambio de metodología de tipo de cambio.
- Nuevas políticas fiscales: establecimiento del impuesto al valor agregado.
- Shock externos: cambios en los precios del petróleo, etc., etc., etc...
- También hay efectos sobre la serie que tienen que ver con el calendario, y que podrían modelarse como variables exógenas recurrentes. Eso lo veremos más adelante.



Fundamento

¿Cómo piensan que pueden ser las intervenciones? Presentamos dos casos posibles.



Índice

1

Fundamentos

2

¿Por qué debemos analizarlo
la intervención?

Análisis de la intervención


Permite un mayor conocimiento de los datos

Investigar sobre la historia de una serie permite mejorar el conocimiento sobre y_t . Recordar, no estimamos por estimar, también analizamos el contexto de la serie.



Se tiene una mejor especificación y estimación del modelo

Las intervenciones y outliers pueden alterar seriamente el patrón de correlación de la serie. Ajustar estos eventos permite mejorar la especificación de un modelo ARIMA y se obtienen mejores estimaciones en los parámetros.




Se tienen mejores pronósticos

Los pronósticos serán más precisos al considerar eventos que se conoce llegasen a afectar o modificar lo sucedido en la serie.

Análisis de la intervención: tipos de intervención

Algún otro que consideren o se acuerden...




Análisis de la intervención: tipos de intervención


Para el presente curso, abarcamos dos tipos de intervenciones, las cuales son:

- **IMPULSO (AO):** cuando solamente el nivel de la observación en el tiempo t_0 es afectado. Aquellos que se reflejan como una elevación o caída momentánea del nivel en t_0 , que desaparece sin influir sobre el comportamiento posterior de la serie. Ejemplo: shocks externos.
- **ESCALÓN (LS):** los que ejercen una influencia sostenida sobre el nivel de la serie, pero dejan intacta la estructura básica de su parte estocástica. El nivel de todas las observaciones a partir de t_0 son afectadas por la misma cantidad. Ejemplo: cambio de la política monetaria.

impulso (AO)



Escalón (LS)



Índice

1

Fundamentos

2

¿Por qué debemos analizarlo
de forma diferente?

3

Modelo ARIMA con
intervención

Modelos ARIMA con variables de intervención

$$\underbrace{\phi(B)Y_t = \theta(B)a_t}_{\text{Modelo ARIMA}} + \underbrace{\omega * I_t}_{\text{Variable de Intervención}} \quad \longrightarrow \quad Y_t = \frac{\theta(B)}{\phi(B)} a_t + \omega * I_t$$
$$I_{o,t} = \begin{cases} 1 & \text{si } t=t_0 \\ 0 & \text{si } t \neq t_0 \end{cases}$$

- Y_t es una serie estacionaria.
- I_t es una variable binaria que toma el valor de una constante c en el momento t_0 .
- ω es una estimación de la distancia entre el valor esperado (antes de la intervención) y el valor observado. Recoge la magnitud del impacto del fenómeno exógeno. También se le conoce como la función de impulso.
- Las variables de intervención aíslan los shocks, ocasionados por variables exógenas (que son determinísticas), del comportamiento sistemático de la serie (recogido con los parámetros ϕ y θ que son estocásticos)

Modelos ARIMA con variables de intervención

- En forma general, la función dinámica de impulso **puede** estar definida por un polinomio racional (sería el caso más complejo... el cual hace referencia a una función polinomial...):


$$\omega_{o,t} = \frac{(\vartheta_o - \vartheta_0 B - \vartheta_0 B^2 - \dots - \vartheta_0 B^s)}{(1 - \delta_1 B - \delta_1 B^2 - \dots - \delta_1 B^r)} I_{o,t} = \frac{\vartheta(B)}{\delta(B)} I_{o,t} \quad I_{o,t} = \begin{cases} 1 & \text{si } t=t_o \\ 0 & \text{si } t \neq t_o \end{cases}$$

Donde:

- t_o denota el momento en que ocurrió la intervención
- $I_{o,t}$ es una variable binaria
- $\omega_{o,t}$ son los residuos de un modelo que contienen un shock en t_o
- $\omega_{o,t} = 0$ para $t < t_o$, lo que indica que antes de haber ocurrido la intervención no existen efectos atribuibles a ella.

Modelos ARIMA con variables de intervención

$$y_t = \underbrace{\frac{w(B)}{\delta(B)} I_t}_{\text{Parte determinística}} + \underbrace{\frac{\theta(B)}{\phi(B)} a_t}_{\text{Parte estocástica}}$$



Ejemplo de función dinámica de intervención:

$$(1 - \phi B)(1 - B)Y_t = \underbrace{\frac{\omega_1}{(1 - \delta B)} I_{1,t} + \omega_2 I_{2,t}}_{\text{Intervención}} + (1 - \theta B^{12})a_t$$



¿Qué poseemos como modelo?

¿Cuántas intervenciones hay?

¿Son similares?

Modelos ARIMA con variables de intervención

- El análisis de intervención puede ser realizado en forma “a priori” o “a posteriori”. Veamos en que consisten cada uno:
1. El análisis *a priori* supone el conocimiento del experto sobre posibles fenómenos que han afectado a la serie. Este es muy utilizado y a mi criterio es el que se debería frecuentar más seguido...
 2. El análisis *a posteriori* supone que no hay conocimiento sobre la serie y en la etapa de verificación de un modelo ARIMA se realiza una inspección de los residuos para detectar outliers, y cambios en la estructura de la serie. Este es el que verificaremos más adelante.

Si ambos enfoques coinciden → ¡YUPI! Sin embargo, ambos paradigmas son bastante válidos.



Modelos ARIMA con variables de intervención: identificación a posterior

- Supongamos que en vez de observar Z_t , en realidad se observa una serie “intervenida” Y_t compuesta por la serie original Z_t más un término de intervención $f(t)$ tipo AO, LS:

$$Y_t = f(t) + Z_t$$

$$\longrightarrow f(t) = \frac{\omega(B)}{\delta(B)} I_{o,t} \quad I_{o,t} = \begin{cases} 1 & \text{si } t=t_o \\ 0 & \text{si } t \neq t_o \end{cases}$$

- Caso de un AO: $Y_t = w * I_t + Z_t$
- Y_t es idéntica a Z_t excepto en una observación, en $t=t_o$, donde Y_t está aumentada (si $w>0$) o disminuida (si $w<0$) en una magnitud de w .

Modelos ARIMA con variables de intervención: identificación a posterior

- El siguiente caso no es el que abarcamos en el curso... pero veámoslo...



Modelos ARIMA con variables de intervención: identificación a posterior

- Si filtramos Y_t con un polinomio $\pi(B)$ y llamamos \mathbf{e}_t los residuos de un modelo ARIMA con efecto de un outlier. Se puede escribir como:

$$\varepsilon_t = \pi(B)Y_t$$

$$\varepsilon_t = (1 - \pi B)Y_t$$

- Si se identifica un modelo ARIMA(1,0,0) y se sustituye en Y_t :

$$Y_t = \omega * I_t + \frac{\theta(B)}{\phi(B)} a_t$$

$$Y_t = \omega * I_t + \frac{1}{(1 - \phi B)} a_t$$

$$\varepsilon_t (1 - \pi B)^{-1} = \omega * I_t + \frac{1}{(1 - \phi B)} a_t$$

- Si $\pi = \phi$, se tiene:

$$\varepsilon_t = w * (1 - \phi_1 B) I_t + a_t$$

Modelos ARIMA con variables de intervención: identificación a posterior

$$\varepsilon_t = w * (1 - \phi_1 B)I_t + a_t$$

$$\varepsilon_t = w * I_t - w * \phi * I_{t-1} + a_t$$

- Entonces los residuos \mathbf{e}_t serán iguales a los \mathbf{a}_t , excepto en \mathbf{t} y en $\mathbf{t-1}$.
- Si $\phi=1$ el modelo sería ARIMA(0,1,0) y se tendría: $\varepsilon_t = w * I_t - w * I_{t-1} + a_t$
- Si utilizamos los residuos \mathbf{e}_t para identificar los cambio, las intervenciones en la detección de los *outliers* que debe considerar que éstos ya tienen el efecto de las diferenciaciones aplicadas a Z_t (¿esto a qué técnica les recuerda?)
- Cuando Z_t no es estacionaria, las mismas diferenciaciones aplican a cada una de las variables de intervención.

Modelos ARIMA con variables de intervención: identificación a posterior

Ejemplo de una intervención tipo AO en Y_t




Figure 8.2 Simulated series z_t , and series Y_t with AO effect at $t = 30$ superimposed.

Modelos ARIMA con variables de intervención: identificación a posterior

Ejemplo del “*footprint*” de una intervención tipo AO en los residuos e_t

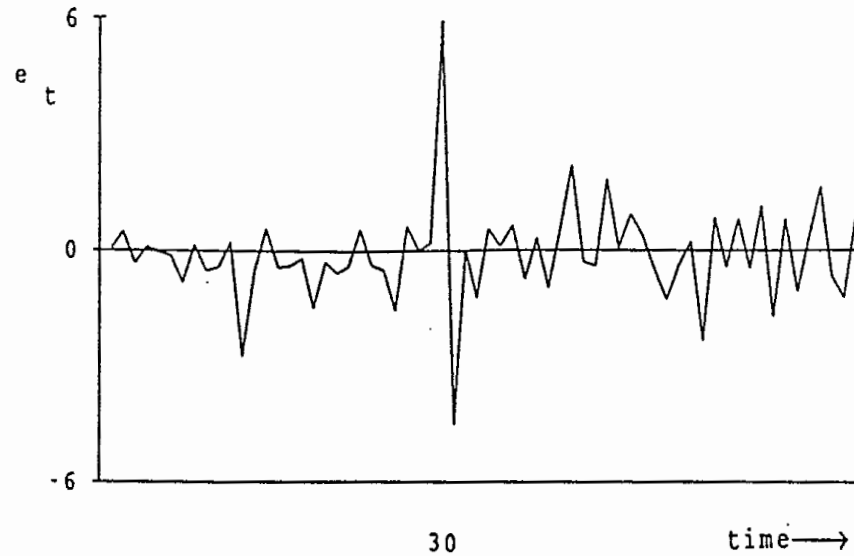


Figure 8.5 Residual series e_t , computed from (8.3.7) applied to series Y_t (with AO) in Figure 8.2.




Figure 8.6 Residual series e_t , minus a_t , for AO example.

Modelos ARIMA con variables de intervención: identificación a posterior

Ejemplo de una intervención tipo LS en Y_t




Figure 8.3 Simulated series z_t , and series Y_t , with LS effect at $t = 30$ superimposed.

Modelos ARIMA con variables de intervención: identificación a posterior

Ejemplo del “footprint” de una intervención tipo LS en los residuos




Figure 8.7 Residual series e_t , computed from (8.3.8) applied to series Y_t (with LS) in Figure 8.3.




Figure 8.8 Residual series e_t , minus a_t , for LS example.



Modelos ARIMA con variables de intervención: aplicación

Veamos dos aplicaciones. Una con una única intervención y otra con más intervenciones en la modelización del presente caso.

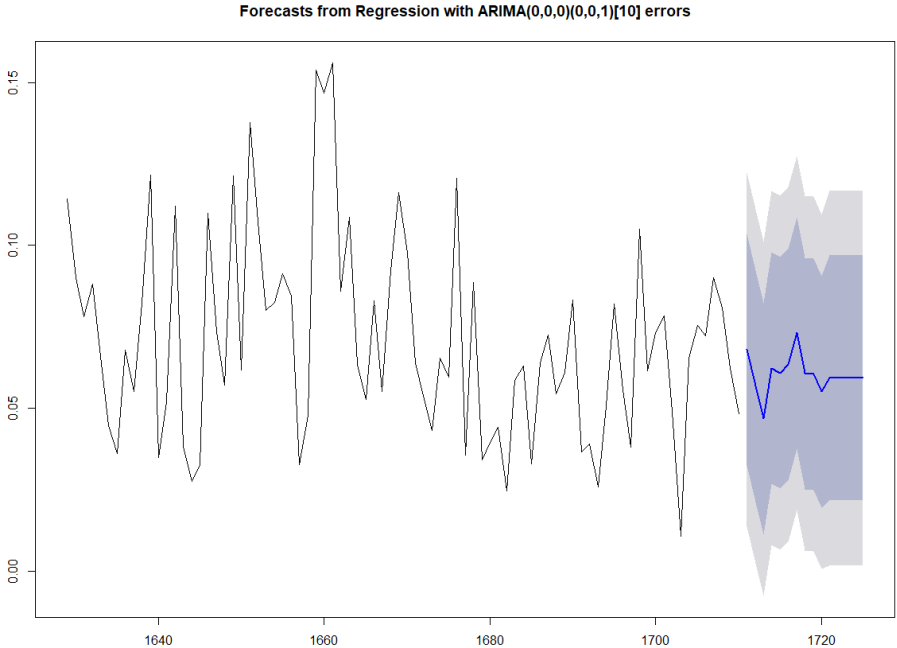



Modelos ARIMA con variables de intervención: aplicación

Taza de variación del género femenino



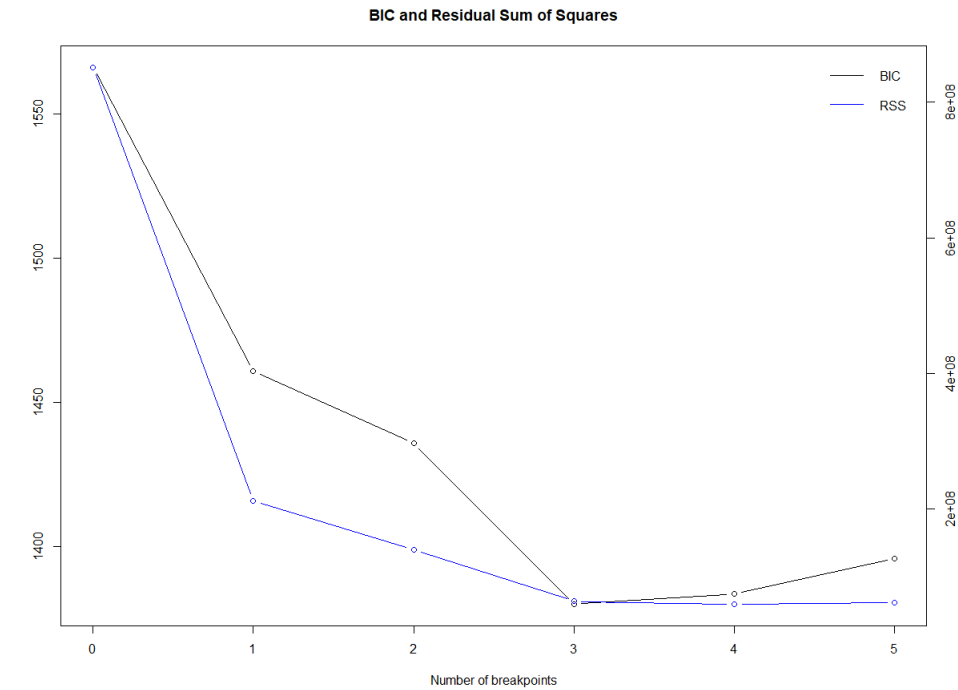

Modelos ARIMA con variables de intervención: aplicación



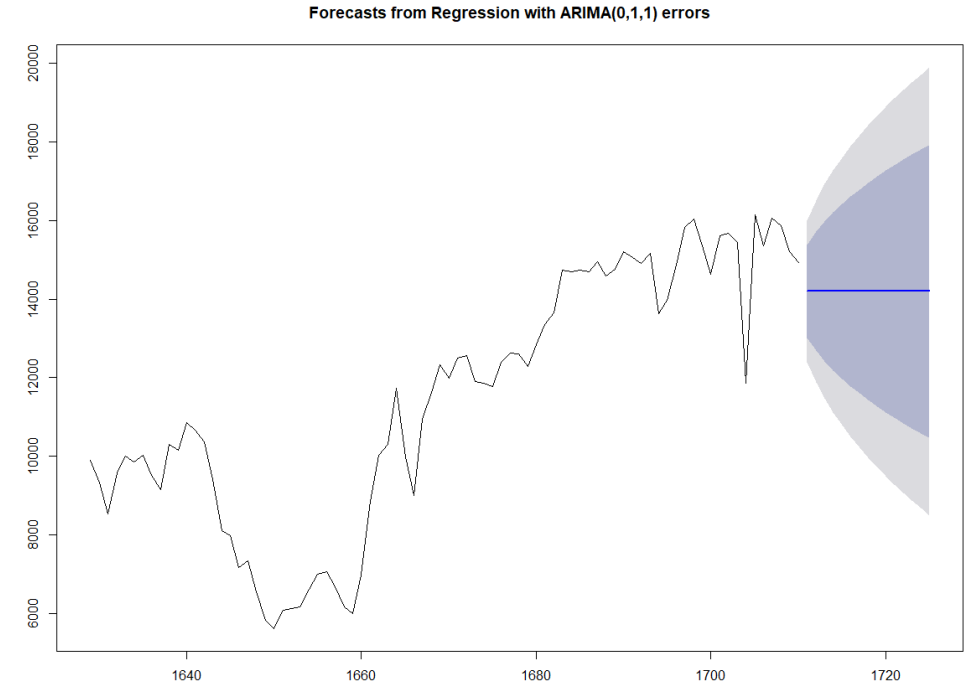

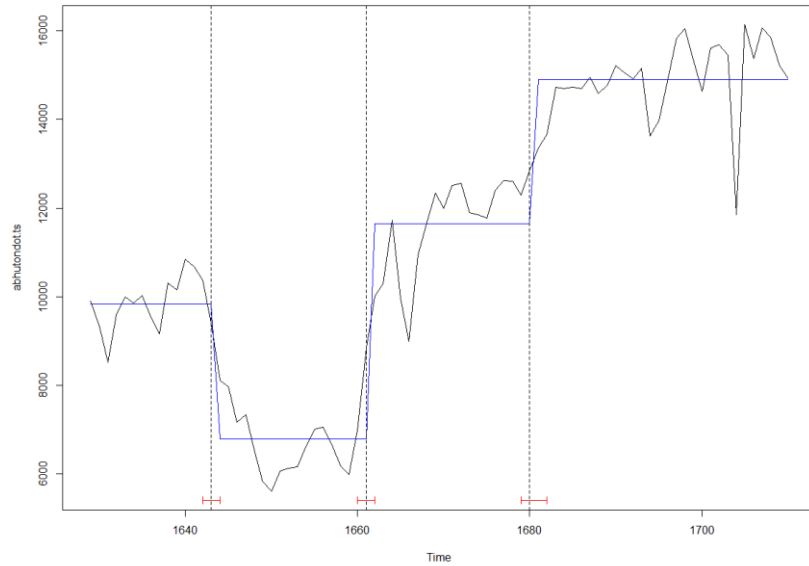
	AIC	AICc	BIC
ARIMA(1,1,1)	-329.8844	-329.5727	-322.7010
ARIMA(1,0,0)(0,0,1)[10]	-344.4575	-343.9380	-334.8306
ARIMA(1,0,0)(1,0,0)[10]	-344.1906	-343.6711	-334.5637
ARIMA(0,0,0)(0,0,1)[10] with level shift	-348.8963	-348.3768	-339.2694
ARIMA(1,0,0) with level shift	-343.3529	-342.8334	-333.7260

Modelos ARIMA con variables de intervención: aplicación

Total de personas



Modelos ARIMA con variables de intervención: aplicación



Pasos para agregar variables de intervención

Cuando no se conocen a priori los fenómenos exógenos que afectan a una serie:

1. Se ajusta el modelo ARIMA sin considerar variables de intervención;
2. Basados en los valores anómalos que se detecten en los residuos e_t (en la etapa de verificación), identificar las posibles variables artificiales que serán necesarias.
3. En cada caso, determinar el momento t_0 en que se existe algún evento exógenos que afectó a la serie y determinar su causa.
4. Agregar las variables artificiales que sean necesarias, una para cada shock, con su estructura de coeficientes.
5. Las variables artificiales para los efectos calendario también se incorporan a la ecuación.
6. Se re-estima el modelo ARIMA incluyendo las variables artificiales.
7. Permanecen en la ecuación las variables artificiales y de calendario que sean significativas.

Pasos para agregar variables de intervención

Alertas de variables de intervención

Se usan como alertas de la necesidad de variables artificiales:

- Valores extremos en el gráfico de los residuos e_t
- Ausencia de normalidad en los residuos
- Valores altos en el correlograma de los residuos en rezagos k que no son múltiplos de s , ni en los primeros rezagos
- El criterio de experto.

Índice

1

Fundamentos

4

Efectos de calendario

2

¿Por qué debemos analizarlo
de forma diferente?

3

Modelo ARIMA con
intervención

Efectos de calendario

Se refiere a los cambios en el calendario que pueden afectar los niveles de la serie y por tanto, afectar las estimaciones del componente estacional y el ajuste del modelo. Estos se pueden ver como intervenciones recurrentes.

- Semana Santa
- Días de comercio
- Años bisiestos
- Feriados móviles
- Carnavales
- Etc...



Efectos de calendario: la semana santa

- Se refiere al efecto que puede tener sobre una variable el hecho de que la Semana Santa sea móvil (marzo/abril). Tiene un efecto significativo en variables de producción (IMAE).
- Se ajusta con una variable *dummy* que contiene unos en los meses donde la Semana Santa está presente. Si la Semana Santa está entre marzo y abril, se pondera cada mes proporcionalmente al número de días festivos de cada mes.
- Véase la siguiente tabla: nótese el efecto de 1999.
¿Qué podemos decir?



	1997	1998	1999	2000
January	0.00	0.00	0.00	0.00
February	0.00	0.00	0.00	0.00
March	1.00	0.00	0.40	0.00
April	0.00	1.00	0.60	1.00
May	0.00	0.00	0.00	0.00
June	0.00	0.00	0.00	0.00
July	0.00	0.00	0.00	0.00
August	0.00	0.00	0.00	0.00
September	0.00	0.00	0.00	0.00
October	0.00	0.00	0.00	0.00
November	0.00	0.00	0.00	0.00
December	0.00	0.00	0.00	0.00

Efectos de calendario: días de comercio

- El patrón “*trading day*” significa que los datos varían dependiendo del número de veces que cada día de la semana ocurre en un mes. Cada día de la semana ocurre 4 ó 5 veces en cada mes. Ejemplo: en un mes con 5 domingos se puede esperar una menor producción en una fábrica que solamente labora de lunes a sábado.
- Por tanto, en series mensuales el valor del agregado mensual depende de la composición del mes en cuanto a el número de días laborables.
- Los distintos días laborables no tienen el mismo nivel de actividad, por tanto, el efecto total X_t se obtiene mediante una regresión al considerar una variable para cada día de la semana.

- El número total de días del mes se puede escribir como:

$$X_t = \delta_1 D_{1t} + \delta_2 D_{2t} + \delta_3 D_{3t} + \delta_4 D_{4t} + \delta_5 D_{5t} + \delta_6 D_{6t} + \delta_7 D_{7t}$$

D_{it} = número de días del tipo i en el mes t

	L	M	X	J	V	S	D
ene-03	4	4	5	5	5	4	4
feb-03	4	4	4	4	4	4	4
mar-03	5	4	4	4	4	5	5
abr-03	4	5	5	4	4	4	4
may-03	4	4	4	5	5	5	4
jun-03	5	4	4	4	4	4	5
jul-03	4	5	5	5	4	4	4
ago-03	4	4	4	4	5	5	5
sep-03	5	5	4	4	4	4	4
oct-03	4	4	5	5	5	4	4
nov-03	4	4	4	4	4	5	5
dic-03	5	5	5	4	4	4	4

Efectos de calendario

Otros feriados y años bisiestos

- Los años bisiestos podrían tener un efecto en la variable de interés, debido a que en febrero de cada cuatro años hay un día adicional.
- Las fiestas se captan con el componente estacional, pero algunas cambian de año en año.
- La población afectada por una fiesta puede cambiar según su carácter (Nacional o regional).
- Incluso si la fiesta cae siempre en el mismo mes, el día de la semana podría ser diferente y el efecto también sería diferente.
- Los paquetes estadísticos especializados en modelos ARIMA contienen calendarios que permiten considerar estas variables en forma sencilla.



Índice

1

Fundamentos

4

Efectos de calendario

2

¿Por qué debemos analizarlo
de forma diferente?

5

Valores faltantes y valores
extremos

3

Modelo ARIMA con
intervención

Valores faltantes y valores extremos

Los datos reales a menudo contienen valores perdidos, observaciones externas y otras características desordenadas. Tratar con ellos a veces puede ser problemático.

Valores faltantes (NA)

Los datos faltantes pueden surgir por muchas razones, y vale la pena considerar si el valor o la observación faltante deberá ser realmente tratada dado que se podría inducir a sesgos en el modelo estimado. Por ejemplo, supongamos que estamos estudiando datos de ventas para una tienda, y los valores faltantes ocurren en días festivos cuando la tienda está cerrada... ¿deberíamos imputar sí o no?

Pudimos más bien provocar un aumento en las ventas como resultado... Si lo permitimos en nuestro modelo de pronóstico, lo más probable es que subestimemos las ventas.

Para tratar los valores faltantes de una buena forma, es usar un modelo de regresión dinámica, con variables ficticias que indiquen si el día es día festivo o el día después del día festivo. Ningún método automatizado puede manejar tales efectos, ya que dependen del contexto de pronóstico específico.

En otras situaciones, el valor faltante puede ser esencialmente un evento aleatoria. Por ejemplo, es posible que alguien se haya olvidado de registrar las cifras de ventas o que el dispositivo de registro de datos haya funcionado mal. Si la sincronización de los datos faltantes no es informativa para el problema de pronóstico, entonces los valores faltantes se pueden manejar más fácilmente, y si podríamos entonces imputar el valor y así mejorar el proceso de estimación y de pronóstico

Valores faltantes y valores extremos

Algunos métodos permiten valores perdidos sin ningún problema. Por ejemplo, el método Naïve continúa funcionando, con el valor no faltante más reciente que proporciona el pronóstico para los futuros períodos de tiempo... en este caso este método me parece genial.

Los modelos como los ARIMA, modelos de regresión dinámica y modelos NNA funcionan correctamente sin causar errores al haber valores faltantes. Sin embargo, otras funciones de modelado no manejan valores faltantes, tales como `ets ()`, `stlf ()` y `tbats ()`, etc, por lo que se deberá en imputar la observación,

Cuando los valores faltantes causan errores en el proceso de estimación, hay al menos dos formas de manejar el problema. Primero, podríamos tomar la sección de datos después del último valor faltante, asumiendo que hay una serie de observaciones lo suficientemente grande o larga como para producir pronósticos significativos (esto sería una forma un poco cobarde de realizar los análisis...). Alternativamente, podríamos reemplazar los valores faltantes con estimaciones. La función `na.interp ()` está diseñada para este propósito. Veamos un ejemplo.

Los datos de **gold** contienen los precios diarios del oro matutino desde el 1 de enero de 1985 hasta el 31 de marzo de 1989. Esta serie fue proporcionada como parte de un proyecto de consultoría; Contiene 34 valores faltantes, así como un valor aparentemente incorrecto.

Valores faltantes y valores extremos



Para datos no estacionales como este, se utiliza la interpolación lineal simple para completar las secciones faltantes. Para los datos estacionales, se utiliza una descomposición STL para estimar el componente estacional, y las series ajustadas estacionalmente son interpoladas linealmente. Se proporciona una interpolación de valor faltante más sofisticada en el paquete `imputeTS`.

<https://cran.r-project.org/web/packages/imputeTS/index.html>

Valores faltantes y valores extremos

- Los valores atípicos son observaciones que son muy diferentes de la mayoría de las observaciones en la serie de tiempo (muy grande, muy pequeñas, o tiene una situación o un movimiento anormal...). Pueden ser errores sistemáticos, o simplemente pueden ser casos inusuales. Todos los métodos que hemos considerado hasta ahora (menos la intervención) no pueden hacer frente cuando se posee valores extremos. Muchas veces se opta por quitarlo del análisis, otras se trabaja el proceso de estimación.
- Reemplazar los valores atípicos sin pensar en por qué han ocurrido es una práctica peligrosa. Pueden proporcionar información útil sobre el proceso que produjo los datos, y que debe tenerse en cuenta al realizar el pronóstico. Sin embargo, si estamos dispuestos a asumir que los valores atípicos son errores genuinos (sistemáticos), o que no ocurrirán en el período de pronóstico, reemplazarlos puede facilitar la tarea de estimación y de pronosticar.
- La función `tsoutliers()` está diseñada para identificar valores atípicos y sugerir valores de reemplazo potenciales. Veamos el caso con el archivo **gold**

Valores faltantes y valores extremos


En el presente caso, el valor “593.7” fue un error de digitación.
El valor correcto era “493.7”

```
> tsoutliers(gold)
$`index`
[1] 770

$replacements
[1] 494.9

>
> gold[768:772]
[1] 495.00 502.75 593.70 487.05 487.75
```

Otra función útil es `tsclean()` que identifica y reemplaza valores atípicos, y también reemplaza valores perdidos. Obviamente, esto debe usarse con cierta precaución, pero nos permite usar modelos de pronóstico que son sensibles a los valores atípicos, o que no manejan los valores faltantes. Por ejemplo, podríamos usar la función `ets()` en la serie **gold**, después de aplicar `tsclean()`.



Los valores atípicos y faltantes se han reemplazado por valores estimados.

Índice

1

Fundamentos

4

Efectos de calendario

2

¿Por qué debemos analizarlo
de forma diferente?

5

Valores faltantes y valores
extremos

3

Modelo ARIMA con
intervención

6

Para la tarea...

Para la siguiente tarea...

- Si cree que en la serie posee intervención, entonces aplique el análisis visto en clases.
- Sino, por favor modifique una parte de su serie, y aplique la intervención, y compare los resultados y la mejora de haber aplicado la intervención.



Conclusión

- El presente capítulo amplió los modelos ARIMA mediante la introducción del análisis por intervención.
- La intervención se puede utilizar tanto para un solo hecho irregular, así como para un cambio de nivel de cierto período.
- Existen dos tipos de intervenciones: las variables indicadores y los polinomeos en los términos de error.
- Los días festivos, años bisiestos, etc., se pueden pensar como intervenciones recurrentes.
- Finalmente, se pueden utilizar ciertas funciones en la limpieza de valores faltantes, así como la detección de valores extremos



*The
End*